

Analysis of Researchers' Online Behavior

Semester project in Data Science

Author: Mohamed Beyrem Kaabachi

Supervisor: Dr. Simon Dumas Primbault

TABLE OF CONTENTS

01

INTRODUCTION

02

LITERATURE REVIEW

03

DATA ACQUISITON & DESCRIPTION

04

METHODOLOGY

05

RESULTS & DISCUSSION

06

QUALITATIVE RESEARCH

07
FUTURE WORK

INTRODUCTION

INTRODUCTION

• Studying libraries and library users is an important subject in the field of ethnography. [3] The goal of **ethnography** is to study the culture and social organization of a particular group or community.

• While observing the behavior of researchers in libraries and laboratories is commonplace in the humanities, the **computational** study of digital research practices is only in its early days.

• This project aims at documenting the behavior of scientists on online platforms by making sense of the **digital traces** they generate while navigating.

INTRODUCTION

• In the context of this project, work has been done on the **browsing logs** of **Gallica** which is the digital library for online users of the Bibliothèque nationale de France and its partners.

• The documents present in that website form an encyclopaedic and comprehensive library, representative of major French authors and of the various trends of reflection and research over the centuries.

• 4.9+ million documents.

LITERATURE REVIEW

LITERATURE REVIEW

• The study of user's behavior in conventional libraries has already been done in previous research. According to a survey [7], there has been a total of 81 studies that researched library users' behaviors as of 2012

• The researcher could either observe or watch subjects in their natural settings [5], conduct interviews with library users [6] or conduct fieldwork in order to contextualize research results. During this project, we are trying to implement a combination of these methods while applying them to a digital resource.

LITERATURE REVIEW

• Interest in digital resources is rising as the platforms become more and more adopted by its users.

- Few notable resources that went over similar subjects:
 - OpenEdition platform Romain Deveaud
 - Wikipedia Robert West
 - · Gallica Nouvellet et al.

• Although our research works on similar data, our goal during this project is to interpret users' behaviors through paths that specifically rely on document themes and how one could go from a theme to another.

DATA MANIPULATION AND ENRICHMENT

DATA DESCRIPTION

• Browsing logs over the month of April 2016.

Information available	Description
Hashed IP	Anonymized IP addresses
Country	Country of requester
City	City of requester
Complete date	Date of request
Request	HTTP requests / ARK requests etc
Protocol	Communication Protocol
Answer Code	Response Status Codes
Length	Length of request
Referring Website	Website from which the user comes

DATA DESCRIPTION

• Request example

```
##6958a5de61066cceb1831af6e2f0fc76##United States##Madison##- -
[04/Mar/2017:00:31:03 +0100] "GET /ark:/12148/bpt6k9708547.lowres HTTP/1.1" 200 78109
"http://gallica.bnf.fr/" "Mozilla/5.0 (Windows NT 6.1; Trident/7.0; rv:11.0) like Gecko"
```

• ARKs the way documents can be requested through Gallica's website. Each ARK is an identifier for a document and does not contain any semantically recognizable information about the document itself. Although it is possible to collect metadata about a document from an ARK by querying the website.

Source: California Digital Library: ARK (n2t.net)

DATA ENRICHMENT

 Query Gallica website using the OAI record: Service for retrieving bibliographic information from a document.

Source: API Document de Gallica | Api (bnf.fr)

- XML answer, several interesting information. Some of them are optional.
- Year
- Language
- Theme Dewey Classification
- Title

Exemple: https://gallica.bnf.fr/services/OAIRecord?ark=bpt6k5738219s

```
<?xml version="1.0" encoding="UTF-8" ?>
<results countResults="1" resultType="LuceneOAIRecordSearch" searchTime="0:00:00.001">
  <notice>
    <record xmlns="http://www.openarchives.org/OAI/2.0/">
      <header>
        <identifier>oai:bnf.fr:gallica/ark:/12148/bpt6k5738219s</identifier>
        <datestamp>2012-01-27</datestamp>
        <setSpec>gallica:theme:8:84</setSpec>
        <setSpec>gallica:typedoc:monographies</setSpec>
      </header>
      <metadata>
        <oai_dc:dc xmlns:dc="http://purl.org/dc/elements/1.1/" xmlns:oai_dc="http://www.openarchives.org/OAI/2.0/oai_dc/</pre>
          <dc:identifier>https://gallica.bnf.fr/ark:/12148/bpt6k5738219s</dc:identifier>
          <dc:title>La plage d'Etretat par l'auteur de "Monsieur X et Mme ***"</dc:title>
          <dc:publisher>Michel Levy (Paris)</dc:publisher>
          <dc:date>1868</dc:date>
          <dc:format>In-18</dc:format>
          <dc:language>fre</dc:language>
          <dc:relation>Notice du catalogue : http://catalogue.bnf.fr/ark:/12148/cb33539190h</dc:relation>
          <dc:type xml:lang="eng">text</dc:type>
          <dc:type xml:lang="fre">monographie imprimée</dc:type>
          <dc:type xml:lang="eng">printed monograph</dc:type>
          <dc:format>application/pdf</dc:format>
          <dc:source>Bibliothèque nationale de France, département Littérature et art, Y2-59413</dc:source>
          <dc:rights xml:lang="fre">domaine public</dc:rights>
          <dc:rights xml:lang="eng">public domain</dc:rights>
        </oai dc:dc>
      </metadata>
    </record>
  </notice>
  <mode_indexation>text</mode_indexation>
  <ngamoyen>092.57</ngamoyen>
  cprovenance>bnf.fr
  <source>Bibliothèque nationale de France, département Littérature et art, Y2-59413</source>
  <typedoc>monographies</typedoc>
  <date>1868</date>
  <title>La plage d'Etretat par l'auteur de "Monsieur X et Mme ***"</title>
  <sdewey>84</sdewey>
</results>
```

TOOLS USED

· Large data provided in logs, reliance on EPFL IC Cluster to do our calculations.







BeautifulSoup for XML Parsing / Data Manipulation using Pandas and Numpy

• Since we are interested in understanding researchers' behaviors, we first start our data manipulation by **creating sessions.** The goal here is to assign a session to each request, where a session is a group of requests emanating from the same user in a constrained period of time.

• A **session** is a series of request that a user made in Gallica website without hitting the inactivity threshold. (Threshold = 60 minutes.)

• Filter only ARK requests

Session				
Session_1	ARK1	ARK2	ARK4	ARK5
Session_2	ARK2	ARK3	ARK1	ARK6


Session				
Session_1	ARK1 - Theme1 - Lang1	ARK2 – Theme2 – Lang2		•••
Session_2	ARK2 - Theme2 - Lang2	ARK3 – Theme3 – Lang3	•••	•••


RESULTS & DISCUSSION


USER PATHS AS MARKOV CHAINS


$$P_{(Theme_i,Theme_j)} = P(X_{n+1} = Theme_j | X_n = Theme_i)$$


$$\hat{P}_{Theme_i,Theme_j} = \frac{n_{Theme_i,Theme_j}}{\sum_{k=1}^{m} n_{Theme_i,Theme_k}}$$

















Technology and Sciences




Literature



Arts



History



USER PATHS AS MARKOV CHAINS

$$Popular Theme = argmax_j(\sum_{k=1}^{m} P_{Theme_k, Theme_j})$$

- Recueils généraux: 0.01% probability of transition on average

$$PopularOutwardsTheme = argmax_{j}(\sum_{k=1}^{m} P_{Theme_{j},Theme_{k}})$$

- Histoire Générale de l'Europe: 0.064% probability of transition on average

REPRESENTATION OF PATHS IN A WORD EMBEDDING FORM

• Creating a corpus

Corpus	
Sentence 1	Theme1, Theme2, Theme3, Theme1, Theme4
Sentence 2	Theme5, Theme2, Theme7, Theme8, Theme4
Sentence 3	Theme6, Theme9, Theme7, Theme2, Theme1

- Word2vec using Skip-gram
- Each Theme is represented as a vector of 200 dimensions.
- Visualization can be obtained with t-SNE.

Animaux Plantes

Littérature des langues romanes, Littérature française Arts graphiques. La gnavures et les gravures

Biographie, généalogie, emblèmes, insignes Histoire générale de l'Amérique du Nord

Fabrications de produits à usages particuliers

Littératures des autres langues Coutumes, savoir-vivre, folklore

Littérature (Belles-lettres) et techniques d'écriture

Histoire générale de l'Europe

Littératures espagnole et portugaise

Philosophie et théorie de la religion

Publications en série d'ordre général

Paléontologie

Christianisme Théologie chrétienne

Sciences de la nature et mathématiques

Manuscrits, livres rares, autres documents imprimés rares

Histoire générale de l'Afrique

Théologie chrétienne et société et ecclésiologi

Histoire générale du monde ancien, jusqu'à 499 apr. J.-C.

Organisations générales et en usé ologique

Agronomie, agricultura et activités connexes é activités connexes sur la Géographie et l'Histoire

Histoire générale de l'Asie. Orient. Extrême-Orient

Géographie et voyages

Littérature des langues germaniques. Littérature allemande

Autres langues

Urbanisme. Art du paysage

Bibliographie Anglais et vieil anglais (anglo-saxon)

Langues romanes. Français

Langues Mareniques. Grec classique

Histoire et géographié disen sprátiennes logales et serdres religieux chrétiens Bibliographie ...

Histoire et géographié disen sprátiennes logales et serdres religieux chrétiens Bibliographie ...

Logique philosophique

Langues espagnole et portugaise Linauistiaue

Éducation, enseignement

Langues l'alfactures des langues italiques. Littérature

Confessions et sectes de l'Église chrétienne de l'information

Sciences sociales

Encyclopédies générales

Recueils généraux

Droit

Littératures des langues helléniques, Littérature


REPRESENTATION OF PATHS IN A WORD EMBEDDING FORM

REPRESENTATION OF PATHS IN A WORD EMBEDDING FORM

"Mathematics is, as it were, a sensuous logic, and relates to philosophy as do the arts, music, and plastic art to poetry." — K. Shegel

REPRESENTING THEMES AS A NETWORK

- All themes in the graph are added as vertices.
- Number of transitions from a theme to another as edges.
- Nose positions done using Fruchterman-Reingold[1] forcedirected algorithm.
- Make use of graph theory features such as betweenness centrality.



REPRESENTING THEMES AS A NETWORK

The betweenness centrality of a node v is given by the expression:

$$g(v) = \sum_{s
eq v
eq t} rac{\sigma_{st}(v)}{\sigma_{st}}$$

where σ_{st} is the total number of shortest paths from nodes s to node t and $\sigma_{st}(v)$ is the number of those paths that pass through v.

A node strength is then given by the sum of the weights of its adjacent edges. With a_{ij} and w_{ij} being adjacency and weight matrices between nodes i and j

$$s_i = \sum_{j=1}^N a_{ij} w_{ij}$$

REPRESENTING THEMES AS A NETWORK

Themes	Betweenness centrality
Histoire générale de l'Europe	0.027
Littérature des langues romanes. Littérature française	0.024
Littératures des langues italiques. Littérature latine	0.0216
Les arts. Beaux-arts et arts décoratifs	0.0214
Médias documentaires, journalisme, édition	0.0174

QUALITATIVE RESEARCH

QUALITATIVE RESEARCH

- Qualitative research: collecting and analyzing non-numerical data (e.g., text, video, or audio) to understand concepts, opinions, or experiences.
- Interview with a Gallica user, key points:
 - Non-linearity of consultations
- Participant observation

```
Le Concordat, sa négociation, ses dix-sept articles, son histoire de 1801 à 1903 , par Auguste Body',
L'ami des hommes, ou Exposé simple des moyens de conserver la santé et de prolonger autant que possible la durée de la vie. Trai
La maison au Moven âge dans le Midi de la France : actes du colloque de Cahors des 6, 7 et 8 juillet 2006 / [organisées par la]
Adèle / par l'auteur de Jean Sbogar",
Histoire et description des voies de communication aux États-Unis... par Michel Chevalier. Table analytique et alphabétique des
Épisodes de la guerre de Trente ans. Le maréchal de Guébriant (1602 à 1643) / par le vicomte de Noailles',
Sommation du château de Montsaugeon par Guébriant (19 avril 1639) . (Signé : Emile Longin.)',
Les papiers de Pierre Rotrou de Saudreville, secrétaire du maréchal de Guébriant : introduction / publiés par Léonce Person,...'
Histoire généalogique de la maison de Lantivy, de ses alliances et des seigneuries qu'elle a possédées, Bretagne, Maine, Anjou 🤅
son (Écosse et France)... par Théodore Courtaux et le Cte de Lantivy de Trédion",
Revue de l'art français ancien et moderne",
Bulletin... / Société de l'histoire du protestantisme français : études, documents, chronique littéraire",
Le Cabinet historique : revue... contenant, avec un texte et des pièces inédites, intéressantes ou peu connues, le catalogue gér
toire de l'ancienne France et de ses diverses localités, avec les indications de sources, et des notices sur les bibliothèques «
Les papiers de Pierre Rotrou de Saudreville, secrétaire du maréchal de Guébriant : introduction / publiés par Léonce Person,...
Épisodes de la guerre de Trente ans. Le maréchal de Guébriant (1602 à 1643) / par le vicomte de Noailles',
Sommation du château de Montsaugeon par Guébriant (19 avril 1639) . (Signé : Emile Longin.)',
Revue d'histoire moderne et contemporaine / Société d'histoire moderne",
Mémoires de Messire Philippe de Comines, seigneur d'Argenton. Tome 1 / , où l'on trouve l'histoire des rois de France Louis XI 🤅
ttres, contrats et instructions... par messieurs Godefroy, augmentée par M. l'abbé LenglDu Fresnoy",
Catalogue de la bibliothèque de la ville de Pau. HISTOIRE Partie 2 / par L. Soulice,... [et Gabriel Loirette]',
Histoire de dix ans de la Franche-Comté de Bourgogne, 1632-1642 / par Girardot de Nozeroy ["sic"], seigneur de Beauchemin...; [
Revue de Gascogne : bulletin mensuel du Comité d'histoire et d'archéologie de la province ecclésiastique d'Auch",
Revue d'histoire littéraire de la France",
Mémoires du maréchal de Turenne. Tome I. 1643-1653 / publiés, pour la Société de l'histoire de France, d'après le manuscrit aut
Mélanges historiques : choix de documents. 1, Tome premier. Tome 1',
Revue de l'art français ancien et moderne",
Histoire généalogique de la maison de Lantivy, de ses alliances et des seigneuries qu'elle a possédées, Bretagne, Maine, Anjou 🤅
son (Écosse et France)... par Théodore Courtaux et le Cte de Lantivy de Trédion",
Le Cabinet historique : revue... contenant, avec un texte et des pièces inédites, intéressantes ou peu connues, le catalogue gér
toire de l'ancienne France et de ses diverses localités, avec les indications de sources, et des notices sur les bibliothèques «
Catalogue de la bibliothèque de la ville de Pau. HISTOIRE Partie 2 / par L. Soulice.... [et Gabriel Loirette]',
Histoire de dix ans de la Franche-Comté de Bourgogne, 1632-1642 / par Girardot de Nozeroy ["sic"], seigneur de Beauchemin...; [
Mémoires de Messire Philippe de Comines, seigneur d'Argenton. Tome 1 / , où l'on trouve l'histoire des rois de France Louis XI 🤅
ttres, contrats et instructions... par messieurs Godefroy, augmentée par M. l'abbé LenglDu Fresnoy",
Revue d'histoire moderne et contemporaine / Société d'histoire moderne",
Revue de Gascogne : bulletin mensuel du Comité d'histoire et d'archéologie de la province ecclésiastique d'Auch".
Mélanges historiques : choix de documents. 1, Tome premier. Tome 1',
Revue d'histoire littéraire de la France",
Mémoires du maréchal de Turenne. Tome I. 1643-1653 / publiés, pour la Société de l'histoire de France, d'après le manuscrit aut
```

Manuel des commissions administratives des comités des départements, en temps de paix et en temps de guerre / par le Dr Duchaus:

Une brigade allemande d'infanterie au combat : Borny, Noisseville, Villers-Bretonneux, Saint-Quentin / par le capitaine Grange,. Recherches sur les générations spontanées et sur la matière, ses propriétés et ses lois / par Michel-Hyacinthe Deschamps,...',

Itinéraire de Paris à Jérusalem et de Jérusalem à Paris, en allant par la Grèce et revenant par l'Egypte, la Barbarie et l'Espag Du Culte de la Sainte Vierge dans l'Église catholique / par le cardinal J. H. Newman, traduction revue et corrigée par un bénédi

1792 à propos de 1892 : les martyrs de septembre / Le Père J. Delbrel,...; avec une lettre-préface de Mgr d'Hulst,...",

Le félibre Félix Gras : poètes contemporains / [signé : Emmanuel des Essarts]',

Principj elementari di musica ... compilati da B. Asioli', L'Informateur des aliénistes et des neurologistes".

Les Trois mousquetaires. Tome 5-6 / par Alexandre Dumas',

La Fleur mauve / par Véra Dérelle',

Style de Pascal / par M. Nault....'

Honneur à Faidherbe',


QUALITATIV E RESEARCH

- Path presented to user
- Maréchal de guébriant
- Maréchaux de France



QUALITATIVE RESEARCH

Path presented to user



QUALITATIVE RESEARCH

• Paths where it is more difficult to understand what the user is looking for.

Key points

Mixed methods

• Understanding user movements, exploratory research/targeted research. Making the data "talk" and validation from a Gallica user.

Topological Data Analysis

FUTURE WORK

Future work

• Distances between sessions using Word Mover's distance.

• Clustering on sessions and identifying trends

• Topological Data Analysis

Thank you.

REFERENCES

• Interest in digital resources is rising as the platforms become more and more adopted by its users.

- Few notable resources that went over similar subjects:
 - OpenEdition platform Romain Deveaud
 - Wikipedia Robert West
 - · Gallica Nouvellet et al.

• Although our research works on similar data, our goal during this project is to interpret users' behaviors through paths that specifically rely on document themes and how one could go from a theme to another.

References

- [1] Thomas M. J. Fruchterman and Edward M. Reingold. "Graph drawing by force-directed placement". In: Software: Practice and Experience 21.11 (1991), pp. 1129-1164. DOI: https://doi.org/10.1002/spe.4380211102. eprint: https://onlinelibrary.wiley.com/doi/pdf/10.1002/spe.4380211102. URL: https://onlinelibrary.wiley.com/doi/abs/10.1002/spe.4380211102.
- [2] Andrew Y. Ng, Michael I. Jordan, and Yair Weiss. "On Spectral Clustering: Analysis and an Algorithm". In: Proceedings of the 14th International Conference on Neural Information Processing Systems: Natural and Synthetic. NIPS'01. Vancouver, British Columbia, Canada: MIT Press, 2001, pp. 849– 856.
- [3] Craig Calhoun. Dictionary of the social sciences. Oxford University Press, 2002.
- [4] Laurens van der Maaten and Geoffrey Hinton. "Viualizing data using t-SNE". In: Journal of Machine Learning Research 9 (Nov. 2008), pp. 2579– 2605.
- [5] Lauren H. Mandel. "Toward an understanding of library patron wayfinding: Observing patrons' entry routes in a public library". In: Library Information Science Research 32.2 (2010), pp. 116-130. ISSN: 0740-8188. DOI: https://doi.org/10.1016/j.lisr.2009.12.004. URL: https://www. sciencedirect.com/science/article/pii/S0740818810000034.
- [6] Kylie Bailin. "Changes in Academic Library Space: A Case Study at The University of New South Wales". In: Australian Academic & Research Libraries 42.4 (2011), pp. 342-359. DOI: 10.1080/00048623.2011.10722245. eprint: https://doi.org/10.1080/00048623.2011.10722245. URL: https://doi.org/10.1080/00048623.2011.10722245.
- [7] Michael Khoo, Lily Rozaklis, and Catherine Hall. "A survey of the use of ethnographic methods in the study of libraries and library users". In: Library Information Science Research 34 (Apr. 2012), pp. 82–91. DOI: 10.1016/j. lisr.2011.07.010.
- [8] Tomas Mikolov, Quoc V. Le, and Ilya Sutskever. Exploiting Similarities among Languages for Machine Translation. 2013. arXiv: 1309.4168 [cs.CL].

- [9] Matt J. Kusner et al. "From Word Embeddings to Document Distances". In: Proceedings of the 32nd International Conference on International Conference on Machine Learning - Volume 37. ICML'15. Lille, France: JMLR.org, 2015, pp. 957–966.
- [10] Adrien Nouvellet et al. "Analyse des traces d'usage de Gallica : Une étude à partir des logs de connexions au site Gallica." In: (2017).
- 11] Archival Resource Key (ARK) Identifiers. URL: https://n2t.net/e/ark_ids.html.
- [12] Romain Deveaud. "Modalités d'accès au savoir ouvert sur les plateformes d'OpenEdition". In: ().
- [13] Gallica The BnF digital library. URL: http://www.bnf.fr/en/gallica-bnf-digital-library.
- [14] Stuart Hannabuss. How to... Use ethnographic methods and participant observation. URL: https://www.emeraldgrouppublishing.com/how-to/observation/use-ethnographic-methods-participant-observation.
- [15] Robert West HUMAN NAVIGATION OF INFORMATION NETWORKS, 2016